

机器学习实验报告/大作业3

学号	姓名
22336221	汪宣彤

一、实验要求

使用PCA降维和决策树分类器实践

【数据集】

Wine Quality数据集中的红酒数据集 **winequality-red.csv**

数据集地址: <https://archive.ics.uci.edu/dataset/186/wine+quality><https://archive.ics.uci.edu/dataset/17/breast+cancer+wisconsin+diagnostic>

【任务要求】

实验一：PCA降维

- 数据预处理
 - 使用pandas加载数据集，并进行标准化处理
- PCA降维
 - 使用PCA对数据进行降维
 - 实验不同的主成分数量（例如2、3、5个主成分），观察数据在降维后特征空间的分布
 - **可视化**降维后的数据，分析信息保留情况

实验二：决策树分类器

- 构建决策树模型
 - 使用原始数据构建**三种不同策略**的决策树模型（CART、ID3、C4.5）（ID3和C4.5在sklearn中没有对应的库，可使用其他库，如id3-decision-tree, c45）
 - 评估每种模型的性能（使用准确率、混淆矩阵等指标）
- 模型优化
 - 通过调整决策树的参数（如最大深度、最小样本分割数等）优化模型性能
- 讨论
 - 比较不同策略的决策树在性能上的差异
 - 讨论各策略的优缺点及适用场景

实验三：PCA与决策树结合

- PCA+决策树
 - 使用PCA降维后的数据构建决策树模型（选一种决策树即可）
 - 对比不同降维数量下的决策树性能
- 综合分析
 - 分析PCA降维对决策树分类性能的影响
 - 探讨在降维后，信息损失与模型复杂度之间的权衡

【实验报告】（内容包括但不限于以下部分）

1. PCA和决策树的相关原理分析
2. 比较不同决策树的性能
3. 对比在不同降维数量下的决策树性能
4. 探讨降维后，信息损失和模型复杂度之间的权衡

二、实验整体原理分析

PCA和决策树的相关原理分析

• PCA

PCA作为无监督降维技术，旨在通过线性变换将数据从高维空间映射到低维空间，同时尽可能保留原数据中的方差，其核心思想是计算数据的协方差矩阵，并通过特征值分解得到主成分，选取包含最大方差的几个主成分进行数据投影

◦ 优点

- 能有效降低数据的维度，且通常能够保留大部分信息

◦ 局限性

- 对数据的线性结构有较强假设，非线性关系无法很好捕捉
- 降维过程中，可能会丢失一些细节信息，导致分类性能下降

• 决策树

决策树作为基于树形结构的监督学习方法，用于分类或回归任务。通过选择最优特征对数据进行划分，每次划分都旨在最大化信息增益或最小化数据的不纯度

◦ 优点

- 不需要对数据进行归一化或标准化等预处理

◦ 局限性

- 在数据噪声较大时，容易发生过拟合
- 对于某些特征的划分，决策树可能过于依赖某些单一特征，导致泛化能力差

• 决策树算法：CART、ID3和C4.5

- **CART**：采用**基尼指数**作为划分标准，适用于分类和回归任务，生成二叉树
- **ID3**：基于**信息增益**选择特征，适用于分类任务，但容易过拟合
- **C4.5**：改进了ID3，使用**信息增益比**来克服ID3的偏倚，支持连续特征和缺失值处理

- **PCA与决策树结合的影响**

- 结合PCA与决策树的优势在于，PCA能保持主要特征信息，同时减少维度，从而降低决策树的计算复杂度，并减少过拟合的风险
- 然而降维也会带来信息损失，特别是在选择较少主成分时，可能影响分类效果

三、实验1：PCA降维

实验原理

主成分分析 (PCA)

PCA是一种线性降维技术，目标是通过线性变换将高维数据映射到低维空间，同时尽可能保留原始数据中的信息

- **方差最大化**：通过寻找数据分布的主方向（主成分），使投影后的数据具有最大的方差
- **正交性**：各主成分相互正交，确保无冗余信息
- **特征分解**：通过对协方差矩阵进行特征值分解或奇异值分解，得到对应的特征向量（主成分）和特征值（解释方差）

PCA的降维效果依赖于保留的主成分数量，主成分数量越多，保留的信息越完整

实验步骤

- **数据加载与预处理**

- 加载数据集
 - 使用 Pandas 加载 `winequality-red.csv` 数据集
- 特征和标签分离
 - 特征 (x) 为化学属性，标签 (y) 为酒的质量评分
 - 将质量评分转为二分类问题
- 数据标准化
 - 使用 `StandardScaler` 将特征数据进行标准化处理（均值为 0，标准差为 1），避免特征尺度差异对 PCA 和模型训练的影响

- **PCA降维**

- 循环不同主成分数量
 - 设定主成分数量为 2、3、5，使用 `PCA` 模块对标准化后的数据进行降维，并记录降维后的结果

- **可视化分析**

- 图示特征空间分布
 - 将降维后的二维数据（2个主成分）绘制为散点图，展示降维后数据在特征空间的分布，并用颜色表示质量评分

关键代码展示

```
# 1. 数据加载与预处理
# 加载数据集
data = pd.read_csv('winequality-red.csv', sep=';')

# 检查数据基本信息
print(data.info())
print(data.describe())

# 分离特征和标签
X = data.drop('quality', axis=1)
y = data['quality']

# 标准化处理
scaler = StandardScaler()
X_scaled = scaler.fit_transform(X)

# 2. PCA降维
# 定义不同的主成分数量
n_components_list = [2, 3, 5]

pca_results = {}
explained_variances = {}

for n in n_components_list:
    pca = PCA(n_components=n)
    X_pca = pca.fit_transform(X_scaled)
    pca_results[n] = X_pca
    explained_variances[n] = pca.explained_variance_ratio_
    print(f'主成分数量: {n}')
    print(f'解释方差比例: {explained_variances[n]}')
```



代码输出

```
PS C:\Users\陆七归\Desktop\code> & C:/Users/陆七归/AppData/Local/Programs/Python/Python310/python.exe c:/Users/陆七归/Desktop/code/lab1.py
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 1599 entries, 0 to 1598
Data columns (total 12 columns):
 #   Column                Non-Null Count  Dtype  
---  -
 0   fixed acidity          1599 non-null   float64
 1   volatile acidity       1599 non-null   float64
 2   citric acid            1599 non-null   float64
 3   residual sugar         1599 non-null   float64
 4   chlorides              1599 non-null   float64
 5   free sulfur dioxide    1599 non-null   float64
 6   total sulfur dioxide   1599 non-null   float64
 7   density               1599 non-null   float64
 8   pH                    1599 non-null   float64
 9   sulphates             1599 non-null   float64
10   alcohol               1599 non-null   float64
11   quality               1599 non-null   int64   
dtypes: float64(11), int64(1)
memory usage: 150.0 KB
None

```

	fixed acidity	volatile acidity	citric acid	residual sugar	chlorides	...	density	pH	sulphates	alcohol	quality
count	1599.000000	1599.000000	1599.000000	1599.000000	1599.000000	...	1599.000000	1599.000000	1599.000000	1599.000000	1599.000000
mean	8.319637	0.527821	0.270976	2.538806	0.087467	...	0.996747	3.311113	0.658149	10.422983	5.636023
std	1.741096	0.179060	0.194801	1.409928	0.047065	...	0.001887	0.154386	0.169507	1.065668	0.807569
min	4.600000	0.120000	0.000000	0.900000	0.012000	...	0.990070	2.740000	0.330000	8.400000	3.000000
25%	7.100000	0.390000	0.090000	1.900000	0.070000	...	0.995600	3.210000	0.550000	9.500000	5.000000
50%	7.900000	0.520000	0.260000	2.200000	0.079000	...	0.996750	3.310000	0.620000	10.200000	6.000000
75%	9.200000	0.640000	0.420000	2.600000	0.090000	...	0.997835	3.400000	0.730000	11.100000	6.000000
max	15.900000	1.580000	1.000000	15.500000	0.611000	...	1.003690	4.010000	2.000000	14.900000	8.000000

```
[8 rows x 12 columns]
主成分数量: 2
解释方差比例: [0.28173931 0.1750827 ]
主成分数量: 3
解释方差比例: [0.28173931 0.1750827 0.1409585 ]
主成分数量: 5
解释方差比例: [0.28173931 0.1750827 0.1409585 0.11029387 0.08720837]
```



实验结果分析

- 数据预处理

数据集包含1599条样本和12个特征，其中11个为浮点数特征，1个为整数标签（质量 `quality`），数据无缺失值

- PCA降维分析

- 解释方差比例

- 主成分数量为2时，前两个主成分共解释了约45.7%的数据方差（28.2% + 17.5%）
 - 主成分数量为3时，前三个主成分共解释了约59.8%的数据方差（28.2% + 17.5% + 14.1%）
 - 主成分数量为5时，前五个主成分共解释了约80%的数据方差，表明此时较多的信息已经被保留

- 累计解释方差比例图

从累计曲线可以看出，前两个主成分解释了近一半的信息，增加更多主成分后解释方差逐步增加，但增益逐渐递减

- 可视化分析

- 二维散点图

- PCA降维到二维后，不同质量评分的样本在散点图中存在一定程度的分离，但仍有较大的重叠，说明酒的质量评分可能与化学特征的线性关系有限
 - 数据的分布较为集中，但有少量离群点（例如右上角的点）

- 解释方差柱状图

第一主成分的方差占比明显高于其他主成分，表明其捕捉了数据中最主要的信息

- 总结

- 降维效果

- PCA降维到2个主成分可以保留约46%的方差信息；当降维到5个主成分时，保留的信息量增加到80%
 - 在实际应用中，主成分数量的选择需要在信息保留和模型复杂性之间权衡

- 数据分布分析

从二维可视化图看，本实验中，酒的质量评分并未完全线性可分

四、实验2：决策树分类器

实验原理

- CART

- 基于**基尼指数**选择分裂特征，分裂后每个节点的样本更加纯净
 - 支持二叉树结构，叶节点表示类别或回归值

- ID3

- 使用**信息增益**作为分裂标准，优先选择使信息熵下降最快的特征进行分裂
 - 不支持连续特征，适合离散数据

- C4.5

- 使用**信息增益比**解决信息增益偏向多值特征的问题
 - 支持连续特征划分，能够处理缺失值，并加入剪枝策略以避免过拟合

实验步骤

- 数据加载与预处理
 - 加载数据集
 - 使用 Pandas 加载 `winequality-red.csv` 数据集
 - 特征与标签分离
 - 特征 (x) 为化学属性, 标签 (y) 为酒的质量评分
 - 将质量评分转为二分类问题
 - 数据集划分
 - 使用 `train_test_split` 将数据划分为训练集和测试集, 比例为 7:3
- 构建决策树模型
 - CART
 - 使用 `sklearn.tree.DecisionTreeClassifier` 构建基于 Gini 指数的决策树
 - 设置 `max_depth=5` 限制树的深度, 防止过拟合
 - ID3 模型
 - 使用 `Id3Estimator` 构建基于信息增益的决策树
 - 设置最大深度为 5
 - C4.5 模型
 - 使用 `C45Classifier` 构建基于信息增益比的决策树
 - 模型支持连续特征, 直接训练并预测测试集
- 模型性能评估
 - 准确率 (Accuracy)
 - 衡量模型预测的整体准确性
 - 混淆矩阵 (Confusion Matrix)
 - 检查模型的预测情况, 分析分类错误的分布
 - 分类报告 (Classification Report)
 - 包括精确率 (Precision)、召回率 (Recall) 和 F1 分数

关键代码展示

```
# 2. 构建决策树模型
# 2.1 CART (sklearn的默认算法)
cart_tree = DecisionTreeClassifier(criterion='gini', random_state=42,
max_depth=5)
cart_tree.fit(X_train, y_train)
cart_pred = cart_tree.predict(X_test)

# 2.2 ID3
id3_tree = Id3Estimator(max_depth=5)
id3_tree.fit(X_train, y_train)
id3_pred = id3_tree.predict(X_test)

# 2.3 C4.5
c45_tree = C45Classifier() # 初始化 C4.5 分类器
c45_tree.fit(X_train, y_train) # 使用训练数据训练模型
c45_pred = c45_tree.predict(X_test) # 对测试集进行预测
```

```

# 3. 模型性能评估
# 3.1 CART
print("CART Decision Tree Performance")
print("Accuracy:", accuracy_score(y_test, cart_pred))
print("Confusion Matrix:\n", confusion_matrix(y_test, cart_pred))
print("Classification Report:\n", classification_report(y_test, cart_pred))

# 3.2 ID3
print("\nID3 Decision Tree Performance")
print("Accuracy:", accuracy_score(y_test, id3_pred))
print("Confusion Matrix:\n", confusion_matrix(y_test, id3_pred))
print("Classification Report:\n", classification_report(y_test, id3_pred))

# 3.3 C4.5
print("\nC4.5 Decision Tree Performance")
print("Accuracy:", accuracy_score(y_test, c45_pred))
print("Confusion Matrix:\n", confusion_matrix(y_test, c45_pred))
print("Classification Report:\n", classification_report(y_test, c45_pred))

# 4. 树结构输出
print("\nCART Tree Structure:")
print(export_text(cart_tree, feature_names=list(X.columns)))

print("\nID3 Tree Structure:")
print(export_text_id3(id3_tree.tree_, feature_names=list(X.columns)))

```

代码输出

```

CART Decision Tree Performance
Accuracy: 0.7083333333333334
Confusion Matrix:
[[146  67]
 [ 73 194]]
Classification Report:

```

	precision	recall	f1-score	support
0	0.67	0.69	0.68	213
1	0.74	0.73	0.73	267
accuracy			0.71	480
macro avg	0.70	0.71	0.71	480
weighted avg	0.71	0.71	0.71	480

```

ID3 Decision Tree Performance
Accuracy: 0.7104166666666667
Confusion Matrix:
[[158  55]
 [ 84 183]]
Classification Report:

```

	precision	recall	f1-score	support
0	0.65	0.74	0.69	213
1	0.77	0.69	0.72	267
accuracy			0.71	480
macro avg	0.71	0.71	0.71	480
weighted avg	0.72	0.71	0.71	480

C4.5 Decision Tree Performance

Accuracy: 0.6666666666666666

Confusion Matrix:

```
[[ 77 136]
 [ 24 243]]
```

Classification Report:

	precision	recall	f1-score	support
0	0.76	0.36	0.49	213
1	0.64	0.91	0.75	267
accuracy			0.67	480
macro avg	0.70	0.64	0.62	480
weighted avg	0.69	0.67	0.64	480

CART Tree Structure:

```
|--- alcohol <= 10.53
|   |--- sulphates <= 0.57
|   |   |--- volatile acidity <= 0.34
|   |   |   |--- alcohol <= 9.65
|   |   |   |   |--- citric acid <= 0.38
|   |   |   |   |   |--- class: 0
|   |   |   |   |--- citric acid > 0.38
|   |   |   |   |   |--- class: 1
|   |   |   |--- alcohol > 9.65
|   |   |   |   |--- class: 1
|   |   |--- volatile acidity > 0.34
|   |   |   |--- total sulfur dioxide <= 98.50
|   |   |   |   |--- residual sugar <= 4.85
|   |   |   |   |   |--- class: 0
|   |   |   |   |--- residual sugar > 4.85
|   |   |   |   |   |--- class: 1
|   |   |   |--- total sulfur dioxide > 98.50
|   |   |   |   |--- pH <= 3.08
|   |   |   |   |   |--- class: 0
|   |   |   |   |--- pH > 3.08
|   |   |   |   |   |--- class: 0
|   |--- sulphates > 0.57
|   |   |--- total sulfur dioxide <= 81.50
|   |   |   |--- volatile acidity <= 0.53
|   |   |   |   |--- sulphates <= 0.67
|   |   |   |   |   |--- class: 1
|   |   |   |   |--- sulphates > 0.67
|   |   |   |   |   |--- class: 1
|   |   |   |--- volatile acidity > 0.53
|   |   |   |   |--- residual sugar <= 1.85
|   |   |   |   |   |--- class: 0
|   |   |   |   |--- residual sugar > 1.85
|   |   |   |   |   |--- class: 0
|   |   |--- total sulfur dioxide > 81.50
|   |   |   |--- total sulfur dioxide <= 105.50
|   |   |   |   |--- total sulfur dioxide <= 102.50
|   |   |   |   |   |--- class: 0
|   |   |   |   |--- total sulfur dioxide > 102.50
|   |   |   |   |   |--- class: 1
|   |   |   |--- total sulfur dioxide > 105.50
|   |   |   |   |--- pH <= 2.94
|   |   |   |   |   |--- class: 0
|   |   |   |   |--- pH > 2.94
|   |   |   |   |   |--- class: 0
```

```
|--- alcohol > 10.53
|   |--- sulphates <= 0.58
|   |   |--- alcohol <= 11.05
|   |   |   |--- alcohol <= 10.85
|   |   |   |   |--- citric acid <= 0.00
|   |   |   |   |   |--- class: 0
|   |   |   |   |--- citric acid > 0.00
|   |   |   |   |   |--- class: 1
|   |   |   |--- alcohol > 10.85
|   |   |   |   |--- residual sugar <= 1.60
|   |   |   |   |   |--- class: 1
|   |   |   |   |--- residual sugar > 1.60
|   |   |   |   |   |--- class: 0
|   |   |--- alcohol > 11.05
|   |   |   |--- volatile acidity <= 0.38
|   |   |   |   |--- residual sugar <= 10.60
|   |   |   |   |   |--- class: 1
|   |   |   |   |--- residual sugar > 10.60
|   |   |   |   |   |--- class: 0
```

```

| | | |--- volatile acidity > 0.38
| | | |--- free sulfur dioxide <= 9.00
| | | |--- class: 0
| | | |--- free sulfur dioxide > 9.00
| | | |--- class: 1
| |--- sulphates > 0.58
| |--- volatile acidity <= 0.91
| |--- alcohol <= 11.25
| |--- chlorides <= 0.09
| |--- class: 1
| |--- chlorides > 0.09
| |--- class: 1
| |--- alcohol > 11.25
| |--- residual sugar <= 7.03
| |--- class: 1
| |--- residual sugar > 7.03
| |--- class: 0
| |--- volatile acidity > 0.91
| |--- class: 0

```

ID3 Tree Structure:

```

alcohol <=10.52
| total sulfur dioxide <=98.50
| | sulphates <=0.57
| | | chlorides <=0.10
| | | | volatile acidity <=0.34: 1 (8/4)
| | | | volatile acidity >0.34: 0 (157/48)
| | | chlorides >0.10: 0 (17)
| | sulphates >0.57
| | | volatile acidity <=0.55
| | | | chlorides <=0.10: 1 (108/56)
| | | | chlorides >0.10: 0 (24/17)
| | | volatile acidity >0.55
| | | | residual sugar <=1.95: 0 (47/14)
| | | | residual sugar >1.95: 0 (56/46)
| total sulfur dioxide >98.50
| | residual sugar <=2.25
| | | volatile acidity <=0.58
| | | | free sulfur dioxide <=35.50: 0 (9/5)
| | | | free sulfur dioxide >35.50: 0 (4)
| | | volatile acidity >0.58: 0 (24)
| | residual sugar >2.25: 0 (48)
alcohol >10.52
| sulphates <=0.58
| | volatile acidity <=0.37
| | | residual sugar <=10.60: 1 (23)
| | | residual sugar >10.60: 0 (1)
| | volatile acidity >0.37
| | | density <=1.00
| | | | pH <=3.53: 1 (26/13)
| | | | pH >3.53: 0 (9/3)
| | | density >1.00
| | | | chlorides <=0.11: 0 (25/4)
| | | | chlorides >0.11: 1 (3)
| sulphates >0.58
| | total sulfur dioxide <=61.50
| | | density <=1.00
| | | | chlorides <=0.10: 1 (213/10)
| | | | chlorides >0.10: 1 (28/6)
| | | density >1.00
| | | | pH <=3.09: 0 (4/1)
| | | | pH >3.09: 1 (9/2)
| | total sulfur dioxide >61.50
| | | density <=0.99: 1 (10)
| | | density >0.99
| | | | pH <=3.32: 1 (15/2)
| | | | pH >3.32: 0 (13/7)

```

实验结果分析

- CART、ID3 和 C4.5 性能比较

- 准确率

- CART: **70.8%**
 - ID3: **71.0%**
 - C4.5: **66.7%**

ID3 和 CART 的性能接近, CART 稍低于 ID3, 而 C4.5 的准确率明显低于其他两个模型。这是因为:

- **ID3 和 CART** 都使用了深度为 5 的决策树, 对此数据集的二分类任务具有较好的适应性
 - **C4.5** 的剪枝策略可能过于保守, 导致模型复杂度降低, 但在训练集中丢失了部分信息

- 混淆矩阵

- CART

- **预测好酒 (class 1)** 的召回率较高 ($194/267 \approx 73\%$), 说明 CART 对好酒的分类性能较好
 - 误分类的普通酒 (class 0) 较多, 有 67 样本被错误分类为好酒

- ID3

- **预测普通酒 (class 0)** 的性能比 CART 略高 ($158/213 \approx 74\%$), 说明 ID3 对普通酒的分类性能略优
 - 误分类的好酒 (class 1) 样本较多, 共有 84 样本被错误分类

- C4.5

- **预测好酒 (class 1)** 的性能较高 ($243/267 \approx 91\%$), 但对普通酒 (class 0) 的召回率非常低, 仅有 36%, 说明该模型倾向于预测好酒
 - 误分类的普通酒较多, 有 136 样本被错误分类

- 分类报告

- CART 和 ID3 的平衡性较好

- F1 分数在两个类别之间较接近 (CART: 0.68 vs 0.73; ID3: 0.69 vs 0.72)
 - **ID3 在精确率和召回率之间的权衡更佳**

- C4.5 的偏分类问题

- 对好酒的召回率 (91%) 高于普通酒的召回率 (36%), 整体模型更偏向好酒类别

- 决策树结构分析

- CART 树

CART 树基于**基尼指数**选择分裂特征, 树结构显示:

- 关键特征: `alcohol`、`sulphates`、`volatile acidity`、`total sulfur dioxide`

- ID3 树

ID3 树基于**信息增益**选择分裂特征, 树结构显示:

- 关键特征: `alcohol` 和 `total sulfur dioxide`

- 偏向类别 1 的原因

- 树结构中 `chlorides > 0.10` 和其他连续特征的分裂规则导致对类别 1 的倾向

模型优化

关键代码展示

```
# 参数优化
max_depth_values = [3, 5, 7, None]

print("=== 参数优化结果 ===")
for max_depth in max_depth_values:
    print(f"\n--- max_depth = {max_depth} ---")

    # CART 优化
    cart_tree = DecisionTreeClassifier(criterion='gini', random_state=42,
max_depth=max_depth)
    cart_tree.fit(X_train, y_train)
    cart_pred = cart_tree.predict(X_test)
    print("\nCART Decision Tree Performance")
    print("Accuracy:", accuracy_score(y_test, cart_pred))
    print("Confusion Matrix:\n", confusion_matrix(y_test, cart_pred))

    # ID3 优化
    id3_tree = Id3Estimator(max_depth=max_depth if max_depth is not None else
float('inf'))
    id3_tree.fit(X_train, y_train)
    id3_pred = id3_tree.predict(X_test)
    print("\nID3 Decision Tree Performance")
    print("Accuracy:", accuracy_score(y_test, id3_pred))
    print("Confusion Matrix:\n", confusion_matrix(y_test, id3_pred))

    # C45 优化
    c45_tree = C45Classifier(max_depth=max_depth)
    c45_tree.fit(X_train, y_train)
    c45_pred = c45_tree.predict(X_test)
    print("\nC4.5 Decision Tree Performance")
    print("Accuracy:", accuracy_score(y_test, c45_pred))
    print("Confusion Matrix:\n", confusion_matrix(y_test, c45_pred))
```

代码输出

```
--- max_depth = 3 ---

CART Decision Tree Performance
Accuracy: 0.6958333333333333
Confusion Matrix:
[[107 106]
 [ 40 227]]

ID3 Decision Tree Performance
Accuracy: 0.675
Confusion Matrix:
[[113 100]
 [ 56 211]]

C4.5 Decision Tree Performance
Accuracy: 0.6666666666666666
Confusion Matrix:
[[ 77 136]
 [ 24 243]]
```

```
--- max_depth = 5 ---

CART Decision Tree Performance
Accuracy: 0.7083333333333334
Confusion Matrix:
[[146  67]
 [ 73 194]]

ID3 Decision Tree Performance
Accuracy: 0.7104166666666667
Confusion Matrix:
[[158  55]
 [ 84 183]]

C4.5 Decision Tree Performance
Accuracy: 0.6666666666666666
Confusion Matrix:
[[ 77 136]
 [ 24 243]]
```

```
--- max_depth = 7 ---

CART Decision Tree Performance
Accuracy: 0.7291666666666666
Confusion Matrix:
[[154  59]
 [ 71 196]]

ID3 Decision Tree Performance
Accuracy: 0.7208333333333333
Confusion Matrix:
[[147  66]
 [ 68 199]]

C4.5 Decision Tree Performance
Accuracy: 0.6666666666666666
Confusion Matrix:
[[ 77 136]
 [ 24 243]]

--- max_depth = None ---

CART Decision Tree Performance
Accuracy: 0.7666666666666667
Confusion Matrix:
[[152  61]
 [ 51 216]]

ID3 Decision Tree Performance
Accuracy: 0.6979166666666666
Confusion Matrix:
[[143  70]
 [ 75 192]]

C4.5 Decision Tree Performance
Accuracy: 0.6666666666666666
Confusion Matrix:
[[ 77 136]
 [ 24 243]]
```

实验结果分析

- CART 的表现
 - 随深度增加，CART 模型的准确率持续提高
 - 因为 CART 决策树能够在更大的深度下细化决策边界，但风险是可能出现过拟合
- ID3 的表现
 - ID3 准确率略低于 CART，但也随深度增加而提高
- C4.5 的表现
 - C4.5 的准确率始终维持在 66.67%，表现较为稳定
- 不同深度下的模型表现
 - 在较小深度（如深度 3）下

- CART 和 ID3 表现相近，CART 略优
- C4.5 明显低于 CART 和 ID3
- 随着深度增加
 - CART 的准确率提升最明显
 - ID3 次之，但逐渐接近 CART
 - C4.5 表现不随深度变化，导致其与其他算法的差距进一步扩大

讨论

【1】比较不同策略的决策树在性能上的差异

性能指标对比

模型	准确率 (Accuracy)	类别 0 F1 分数	类别 1 F1 分数	偏向性
CART	70.8%	0.68	0.73	平衡
ID3	71.0%	0.69	0.72	平衡
C4.5	66.7%	0.49	0.75	偏向类别 1 (好酒)

- 准确率
 - ID3 和 CART 准确率接近，C4.5 的准确率略低，主要是因为对类别 0（普通酒）的召回率较低
 - CART 和 ID3 更适合在当前数据集上分类任务的整体需求
- 类别偏向
 - CART 和 ID3：表现出更平衡的分类能力，在两个类别上的 F1 分数差距较小
 - C4.5：对类别 1（好酒）的召回率高达 91%，但牺牲了对类别 0 的分类能力（召回率仅 36%），在偏分类任务上具有一定优势
- 决策规则复杂度
 - CART：树结构复杂，分裂规则直观，基于主要特征（如 alcohol 和 sulphates）分层决策
 - ID3：规则的层次与 CART 类似，但基于信息增益的分裂策略，更多依赖关键特征的贡献
 - C4.5：剪枝策略降低了树的复杂性，但可能丢失了对类别 0 的重要分裂规则
- 总结
 - ID3 和 CART：性能相似，分类能力平衡，适合多类别数据的整体分类任务
 - C4.5：泛化能力强，但在当前数据集上对类别 0 的分类性能较差，适用于关注特定类别召回率的应用

【2】各策略的优缺点及适用场景

- CART
 - 优势
 - 直观性强：基于基尼指数，树结构清晰，分裂规则容易理解
 - 适合分类和回归任务
 - 劣势
 - 容易过拟合：如果不限制树深度，CART 在复杂数据上可能生成过深的树

- 偏向简单特征：基尼指数偏向于较简单的特征分裂，可能导致重要特征被忽略
- 适用场景
 - 适合需要平衡两类分类性能的场景
 - 适用于任务复杂度适中、特征可解释性较高的场景
- ID3
 - 优势
 - 分类性能好：基于**信息增益**的分裂标准，优先选择对分类最有帮助的特征
 - 较好的类别平衡：适合处理平衡分类任务
 - 劣势
 - 不支持连续特征：ID3 无法直接处理连续值，需要预先离散化特征
 - 对多值特征的偏好：信息增益标准偏向于选择取值多的特征，可能导致分裂规则复杂
 - 适用场景
 - 适用于数据是离散型特征，或特征离散化后仍保留显著信息的场景
- C4.5
 - 优势
 - 支持连续特征：C4.5 能够处理连续值，分裂时自动选择最优分割点
 - 剪枝策略：通过后剪枝避免过拟合，提升模型的泛化能力
 - 信息增益比：克服了 ID3 偏向多值特征的缺点
 - 劣势
 - 分类偏向性：剪枝可能削弱对某些类别的分类能力，导致偏分类问题
 - 计算复杂度高：连续特征处理和剪枝策略增加了计算开销
 - 适用场景
 - 适用于需要泛化能力强的分类任务，尤其是偏向特定类别的应用

五、实验3：PCA与决策树结合

实验步骤

- 数据加载与预处理
 - 加载数据集
 - 使用 Pandas 加载 `winequality-red.csv` 数据集
 - 特征和标签分离
 - 特征 (x) 为化学属性，标签 (y) 为酒的质量评分
 - 将质量评分转为二分类问题
 - 数据标准化
 - 使用 `StandardScaler` 将特征数据进行标准化处理（均值为 0，标准差为 1），避免特征尺度差异对 PCA 和模型训练的影响
 - 数据集划分
 - 使用 `train_test_split` 将数据划分为训练集和测试集，比例为 7:3
- PCA 降维与 ID3 决策树分类
 - 循环不同主成分数量
 - 设定主成分数量为 2、3、5，分别对训练集和测试集进行 PCA 降维
 - 训练 ID3 决策树模型
 - 限制决策树最大深度为 7，防止过拟合

- 使用降维后的数据训练模型
- 模型性能评估
 - 使用测试集数据进行预测，计算分类准确率、混淆矩阵和分类报告

关键代码展示

本实验中的决策树选择 id3

```
# 2. PCA 降维与模型训练
def evaluate_pca_with_id3(n_components):
    print(f"\n--- PCA with {n_components} components ---")

    # PCA 降维
    pca = PCA(n_components=n_components)
    X_train_pca = pca.fit_transform(X_train)
    X_test_pca = pca.transform(X_test)

    # 构建 ID3 决策树模型
    id3_tree = Id3Estimator(max_depth=7) # 限制最大深度为7
    id3_tree.fit(X_train_pca, y_train)
    y_pred = id3_tree.predict(X_test_pca)

    # 评估模型性能
    accuracy = accuracy_score(y_test, y_pred)
    conf_matrix = confusion_matrix(y_test, y_pred)
    class_report = classification_report(y_test, y_pred)

    # 打印结果
    print(f"Accuracy: {accuracy}")
    print(f"Confusion Matrix:\n{conf_matrix}")
    print(f"Classification Report:\n{class_report}")

# 3. 对比不同主成分数量下的性能
for n_components in [2, 3, 5]: # 实验不同的主成分数量
    evaluate_pca_with_id3(n_components)
```

代码输出

```
--- PCA with 2 components ---
Accuracy: 0.6354166666666666
Confusion Matrix:
[[152  61]
 [114 153]]
Classification Report:
              precision    recall  f1-score   support

     0       0.57         0.71         0.63         213
     1       0.71         0.57         0.64         267

 accuracy          0.64
 macro avg         0.64         0.64         0.64         480
weighted avg         0.65         0.64         0.64         480
```



```
--- PCA with 3 components ---
```

```
Accuracy: 0.6458333333333334
```

```
Confusion Matrix:
```

```
[[179 34]
```

```
 [136 131]]
```

```
Classification Report:
```

	precision	recall	f1-score	support
0	0.57	0.84	0.68	213
1	0.79	0.49	0.61	267
accuracy			0.65	480
macro avg	0.68	0.67	0.64	480
weighted avg	0.69	0.65	0.64	480

```
--- PCA with 5 components ---
```

```
Accuracy: 0.64375
```

```
Confusion Matrix:
```

```
[[114 99]
```

```
 [ 72 195]]
```

```
Classification Report:
```

	precision	recall	f1-score	support
0	0.61	0.54	0.57	213
1	0.66	0.73	0.70	267
accuracy			0.64	480
macro avg	0.64	0.63	0.63	480
weighted avg	0.64	0.64	0.64	480

实验结果分析

- 总体性能概述

观察实验结果可知，使用 **2、3、5 个主成分**进行降维后的 ID3 决策树性能都在 **0.64 左右**，模型的准确率变化不大。然而，混淆矩阵和分类报告显示，降维数量对分类性能的细节影响较为显著

- 不同主成分数量下的决策树性能比较

- PCA with 2 components

- 准确率最低（63.54%），特别是对于类别 **1**（好酒）的召回率仅为 **57%**，说明模型对好酒的识别较弱
 - 混淆矩阵显示类别 **1** 的预测错误（即误分类为类别 **0** 的数量）较多

- PCA with 3 components

- 准确率略有提升（64.58%），尤其是类别 **0**（普通酒）的召回率提高到 **84%**，说明降维后模型在普通酒分类上表现更好
 - 但类别 **1** 的召回率降低为 **49%**，即模型对好酒的识别能力有所下降

- PCA with 5 components

- 准确率略降至 **64.38%**，总体性能趋于稳定
 - 类别 **1** 的召回率提升到 **73%**，表现出较好的平衡性
 - 然而类别 **0** 的召回率降低为 **54%**，说明普通酒的误分类率较高

讨论

【1】PCA降维对决策树分类性能的影响分析

- 降维带来的特征信息压缩

PCA在降维的过程中，部分原始特征信息被压缩或丢失。对于决策树而言，特征数量和特征质量对分类性能影响显著，因此，降维后的决策树性能在以下方面受到影响：

- 信息损失

- PCA降维保留的是数据方差最大的方向，可能忽略了对分类至关重要但方差较小的特征，导致决策树的分类能力减弱

- 降噪效果

- PCA可以过滤掉部分噪声或冗余特征，从而使得模型更加简化，避免过拟合

- 实验结果中的影响

观察实验结果，降维对分类性能的影响：

- 2 个主成分

- 由于降维后仅保留两个主要特征，丢失了许多可能与分类相关的重要信息，模型对类别 1（好酒）的区分能力明显下降
 - 混淆矩阵显示类别 1 的误分类数量较多，说明分类边界模糊

- 3 个主成分

- 增加一个主成分后，模型性能有所提升，特别是类别 0 的召回率从 71% 提升到 84%
 - 这表明此时能够有效保留更多与分类相关的特征，同时减少了噪声特征的干扰

- 5 个主成分

- 尽管保留更多主成分，但分类性能仅有微弱提升（准确率下降），这表明增加的主成分未能显著改善分类边界

- 降维对决策树复杂度的影响

PCA降维通过减少输入特征的数量，直接降低了决策树模型的复杂度

- 特征数量减少

- 特征数量从原始的维度降低到 2、3 或 5 个，决策树的分支深度和规则数量随之减少

- 降低过拟合风险

- 决策树模型在高维空间容易过拟合，而降维可以减少无关或冗余特征对模型训练的干扰

- 模型推理速度更快

- 降维后，模型的分裂计算和预测速度显著提高

然而，实验结果显示，当主成分数量不足（如 2 个主成分）时，虽然模型复杂度降低，但由于信息丢失，模型性能明显下降

【2】信息损失与模型复杂度的权衡

- 信息保留与信息损失

- 主成分数量越少，降维后的数据特征维度越低，特征中包含的信息量越少，导致分类性能受到一定限制。特别是在降到 2 个主成分时，模型的区分能力明显下降
 - 当主成分数量增至 3 个或 5 个时，更多的信息被保留，模型性能有所提升

- 模型复杂度

- 主成分数量越多，输入特征的维度越高，模型的复杂性也随之提高。这可能导致模型在训练和预测时需要更多的计算资源
 - 从实验结果来看，增加到 5 个主成分对分类性能的边际收益开始减小，说明适度降维是必要的