

机器学习与数据挖掘/作业2

姓名	学号
汪宣彤	22336221

1. 回归任务和分类任务有什么本质性的区别，回归模型可以做分类任务吗，如果可以的话需要做什么调整，不行请说明原因

1) 回归任务和分类任务有什么本质性的区别

回归任务和分类任务的本质区别在于它们的目标变量（输入）的性质不同

- **回归任务**的目标变量是**连续值**，模型的输出是一个连续的数值
- **分类任务**的目标变量是**离散值**，模型的输出是不同类别的标签或概率

2) 回归模型可以用于分类任务吗？

回归模型**可以**在某些情况下用于分类任务，需要做出如下调整：

1. 输出映射到离散类

回归模型输出的是一个连续值，因此需要将这些连续值映射到分类任务的离散类。例如，对于二分类任务可以设置**阈值**，如0.5，来将回归模型的输出结果转化为类别0或类别1。这种方法可以扩展到多分类任务，设置多个阈值或采用分箱技术

2. 损失函数

回归模型通常使用均方误差（MSE）作为损失函数，而分类任务则使用交叉熵损失函数。因此，在应用回归模型处理分类任务时，损失函数需要根据分类需求进行改造

2. linear classifier不能表示什么问题？二分类交叉熵损失函数如何表示？如果是多分类呢？

1) Linear classifier 不能表示什么问题？

线性分类器不能很好地表示**非线性可分**问题

- 线性分类器一般通过一条或一个超平面将数据集划分为不同的类别，因此它只能解决数据在特征空间中线性可分的问题
- 如果数据的类别之间存在复杂的非线性关系，线性分类器无法有效地学习这些复杂的边界

2) 二分类交叉熵损失函数如何表示？

假设 $y \in \{0, 1\}$ ，预测的类别概率为 $\hat{y}$ ，那么二分类交叉熵损失函数的形式为：

$$Loss_{\text{binary}} = -(y \log(\hat{y}) + (1 - y) \log(1 - \hat{y}))$$

其中：

- y 为真实标签，取值为0或1

- $\hat{y}$ 为模型预测的概率，即预测样本属于正类（1）的概率

3) 多分类交叉熵损失函数如何表示？

假设有 K 个类别， $y \in \{1, 2, \dots, K\}$ ，模型输出的是每个类别的概率分布 $\hat{y}_k$ （模型对每个类别 k 的预测概率），那么多分类交叉熵损失函数可以表示为：

$$Loss_{\text{multi-class}} = - \sum_{k=1}^K y_k \log(\hat{y}_k)$$

其中：

- y_k 是类别 k 的真实标签
- $\hat{y}_k$ 是模型对类别 k 的预测概率

3. 对于多分类任务通常有哪几种做法？

1) Softmax函数 + 交叉熵损失

- **Softmax函数**

Softmax将模型的输出转化为每个类别的概率分布

假设有 K 个类别，Softmax 的输出为：

$$P(y = k|x) = \frac{e^{z_k}}{\sum_{i=1}^K e^{z_i}}$$

其中：

- z_k 是类别 k 的得分
- $P(y=k|x)$ 是模型预测输入 x 属于类别 k 的概率
- **交叉熵损失**

用于衡量真实类别与模型预测的概率分布之间的差异

$$Loss = - \sum_{k=1}^K y_k \log(\hat{y}_k)$$

其中：

- y_k 是真实标签
- $\hat{y}_k$ 是模型预测的概率

2) One-vs-Rest, 一对多分类

One-vs-Rest 方法将**多分类问题分解为多个二分类问题**，每个二分类模型负责区分某一个类别与其他所有类别

- 对于 K 个类别，训练 K 个二分类模型，每个模型用来预测样本是否属于特定类别
- 最终的预测结果是选择概率最高的二分类模型的输出

这种方法的优势在于简单易实现，可以将多分类任务转化为二分类问题来解决，适用于支持二分类模型的算法

3) One-vs-One, 一对一分类

One-vs-One 方法将**多分类问题分解为类别两两之间的二分类问题**：

- 对于 K 个类别，训练 $\frac{K(K-1)}{2}$ 个二分类模型，每个模型只区分两个类别
- 最终的预测结果通过投票法（多数投票）决定哪个类别为最终预测

这种方法在类别数量较少时效果较好，但当类别过多时会增加计算复杂度和模型数量

4. 在分类任务中，Softmax函数公式是什么？它在分类任务中常常用来做什么？请描述Softmax的输出含义

1) Softmax 函数公式

Softmax 函数的公式如下：

$$P(y = k|\mathbf{x}) = \frac{e^{z_k}}{\sum_{i=1}^K e^{z_i}}$$

其中：

- z_k 是类别 k 的得分
- K 是类别的总数
- $P(y = k|\mathbf{x})$ 是模型预测输入 $\mathbf{x}$ 属于类别 k 的概率

2) Softmax 函数在分类任务中的用途

Softmax 函数常用于**多分类任务**的最后一层神经网络输出，目的是将模型输出的**未归一化的得分转换为概率分布**。它的主要作用是：

- **输出概率分布**

Softmax 函数将原始的得分换为 0 到 1 之间的概率值，这些概率之和为 1。这样模型就可以直接输出样本属于每个类别的概率

- **多分类问题中的决策**

在多分类任务中，模型通过选择 Softmax 函数输出概率最大的类别作为最终的分类结果，即选择类别 k 使得 $P(y = k|\mathbf{x})$ 最大

3) Softmax 输出的含义

Softmax 函数输出的含义是**每个类别的预测概率**，表示模型认为输入样本属于该类别的可能性有多大

- 对于 K 个类别，Softmax 函数输出 K 个概率值，每个概率 $P(y = k|\mathbf{x})$ 对应一个类别 k
- 这些概率值的总和为 1，保证每个类别的概率表示相对的可能性
- 在分类任务中，最终通常选取概率最大的类别作为预测结果

5. 在概率视角中，我们知道了分类任务的交叉熵损失函数为

$$\text{cross entropy} \triangleq -y \log \sigma(\mathbf{xw}) - (1 - y) \log (1 - \sigma(\mathbf{xw}))$$

如何使用梯度下降法去优化该损失函数，请具体推导过程

1) 交叉熵损失函数

给出的交叉熵损失函数为：

$$crossentropy = -y \log(\sigma(xw)) - (1 - y) \log(1 - \sigma(xw))$$

其中：

- y 是真实标签，取值为 0 或 1
- $\sigma(xw)$ 是模型的预测输出，是通过输入 x 和权重 w 的乘积，然后经过 Sigmoid 函数得到的概率。即 $\sigma(z) = \frac{1}{1+e^{-z}}$ ，其中 $z = xw$

2) 使用梯度下降优化

为了使用梯度下降法优化该损失函数，需要对权重 w 求导

1. 对 w 求导

首先对交叉熵损失函数的每个部分分别求导。记 $z = xw$ ， $\sigma(z) = \frac{1}{1+e^{-z}}$

1. 对 $\sigma(xw)$ 求导

Sigmoid 函数的导数为： $\frac{d}{dz} \sigma(z) = \sigma(z)(1 - \sigma(z))$

2. 交叉熵损失函数对 z 的导数

$$\frac{\partial \text{Cross Entropy}}{\partial z} = \sigma(z) - y$$

其中， $\sigma(z)$ 是预测的概率， y 是真实标签

2. 对 w 的导数

由于 $z = xw$ ，根据链式法则，可以继续对 w 求导

$$\frac{\partial \text{Cross Entropy}}{\partial w} = \frac{\partial \text{Cross Entropy}}{\partial z} \cdot \frac{\partial z}{\partial w} = (\sigma(z) - y) \cdot x$$

3. 梯度下降更新公式

现在得到了交叉熵损失函数对权重 w 的梯度为 $(\sigma(xw) - y) \cdot x$ 。在梯度下降法中，更新权重 w 的公式为：

$$w = w - \alpha \cdot \nabla_w$$

其中：

- α 是学习率，控制更新的步长
- $\nabla_w = (\sigma(xw) - y) \cdot x$ 是梯度

所以更新公式为：

$$w := w - \alpha \cdot (\sigma(xw) - y) \cdot x$$

